

LAPORAN UAS NATURAL LANGUAGE PROCESSING

Pemodelan ABSA Review Google Places: Multilabel Text Classification dan Named Entity Recognition

1. Pendahuluan

Proyek UAS Natural Language Processing ini merupakan kelanjutan dari proyek UTS Aspect-Based Sentiment Analysis (ABSA) pada review Google Places. Dataset yang telah dikumpulkan dan dianotasi pada proyek UTS digunakan kembali untuk membangun dua model utama, yaitu Multilabel Text Classification dan Named Entity Recognition (NER).

Multilabel Text Classification digunakan untuk memprediksi satu atau lebih label aspek dan sentimen pada level review, misalnya `PRODUCT_POSITIVE`, `PRICE_NEGATIVE`, `PLACE_POSITIVE`, atau `OUT_OF_TOPIC`. Sementara itu, Named Entity Recognition digunakan untuk mengenali bagian teks atau span yang menunjukkan aspek tertentu, seperti `PRODUCT`, `PRICE`, `PLACE`, dan `PROMOTION`.

Tujuan proyek ini adalah membangun sistem ABSA yang mampu memprediksi aspek dan sentimen review, mengekstraksi span/aspek dari teks review, serta menampilkan hasil prediksi dalam aplikasi Streamlit.

2. Deskripsi Dataset

Dataset yang digunakan merupakan dataset hasil proyek UTS. Dataset utama berasal dari file anotasi Prodigy dalam format JSONL, yaitu:

Kelp4_dataset_anotasi.jsonl

Dataset berisi beberapa kolom utama sebagai berikut:

Kolom	Keterangan
text	Teks review pelanggan
accept	Label multilabel ABSA pada level review
tokens	Token hasil anotasi
spans	Span/entity hasil anotasi
answer	Status anotasi, misalnya accept atau ignore

Pada tahap validasi, hanya data dengan status answer = accept yang digunakan. Data tanpa label pada kolom accept juga dihapus karena tidak memiliki target label untuk proses training.

Ringkasan jumlah data:

Keterangan	Jumlah
Data awal	2118
Data dengan answer = accept	2117
Data tanpa label	14
Data valid setelah filtering	2103

Data train	1682
Data validation	210
Data test	211

Dataset kemudian dibagi menjadi dua bentuk, yaitu dataset Multilabel Classification dalam format CSV dan dataset NER dalam format JSONL dengan skema BIO.

3. Skema Label ABSA

Skema label ABSA terdiri dari empat aspek utama, yaitu PRODUCT, PRICE, PLACE, dan PROMOTION. Setiap aspek memiliki tiga sentimen, yaitu POSITIVE, NEGATIVE, dan NEUTRAL. Selain itu, terdapat label OUT_OF_TOPIC.

Label multilabel yang digunakan adalah:

No	Label
1	PRODUCT_POSITIVE
2	PRODUCT_NEGATIVE
3	PRODUCT_NEUTRAL
4	PRICE_POSITIVE
5	PRICE_NEGATIVE
6	PRICE_NEUTRAL
7	PLACE_POSITIVE
8	PLACE_NEGATIVE
9	PLACE_NEUTRAL
10	PROMOTION_POSITIVE
11	PROMOTION_NEGATIVE
12	PROMOTION_NEUTRAL
13	OUT_OF_TOPIC

Untuk proyek NER, label span dikonversi ke format BIO dengan tag:

B-PRODUCT, I-PRODUCT, B-PRICE, I-PRICE, B-PLACE, I-PLACE, B-PROMOTION, I-PROMOTION, dan O.

Tag B- menunjukkan awal entitas, I- menunjukkan lanjutan entitas, dan O menunjukkan token yang bukan bagian dari entitas.

4. Proyek A: Multilabel Text Classification ABSA

4.1 Alur Pemodelan Multilabel

Pada proyek Multilabel Text Classification, input model adalah teks review, sedangkan output model adalah satu atau lebih label ABSA. Tahapan yang dilakukan adalah:

1. Membaca dataset anotasi.
2. Memvalidasi kolom teks dan label.
3. Menghapus data yang tidak valid atau tidak memiliki label.
4. Melakukan encoding label menjadi format multilabel biner.
5. Melakukan preprocessing teks.
6. Melakukan EDA dan visualisasi label.
7. Membagi data menjadi train, validation, dan test.
8. Membuat representasi teks menggunakan TF-IDF dan Bag of Words.
9. Melatih beberapa model multilabel.
10. Mengevaluasi model dan memilih model terbaik.
11. Menyimpan model terbaik untuk deployment Streamlit.

4.2 Preprocessing dan Label Engineering

Preprocessing teks dilakukan dengan beberapa langkah, yaitu mengubah teks menjadi huruf kecil, menghapus URL, menghapus simbol atau karakter non-huruf, menghapus spasi berlebih, dan menangani negasi sederhana.

Contoh penanganan negasi: Baksonya tidak enak

diubah menjadi: baksonya tidak tidak_enak

Penanganan negasi dilakukan karena model awal dapat salah membaca kata enak sebagai sinyal positif, padahal frasa tidak enak bermakna negatif.

Label engineering dilakukan dengan mengubah daftar label pada kolom accept menjadi 13 kolom biner. Nilai 1 menunjukkan label muncul pada review, sedangkan nilai 0 menunjukkan label tidak muncul.

4.3 EDA dan Visualisasi Multilabel

Distribusi label menunjukkan bahwa dataset tidak seimbang. Label yang paling dominan adalah PRODUCT_POSITIVE, sedangkan label yang paling sedikit adalah PLACE_NEUTRAL.

Label	Jumlah
PRODUCT_POSITIVE	1641
OUT_OF_TOPIC	698
PLACE_POSITIVE	537
PROMOTION_POSITIVE	290
PRODUCT_NEGATIVE	242
PLACE_NEGATIVE	192
PRICE_POSITIVE	181
PROMOTION_NEGATIVE	131

PRODUCT_NEUTRAL	113
PRICE_NEGATIVE	43
PRICE_NEUTRAL	24
PROMOTION_NEUTRAL	23
PLACE_NEUTRAL	9

Distribusi tersebut menunjukkan bahwa label positif, terutama PRODUCT_POSITIVE, jauh lebih dominan dibandingkan label negatif dan netral. Hal ini menyebabkan model lebih mudah mempelajari label dominan dan lebih sulit memprediksi label minoritas.

EDA yang dilakukan pada proyek multilabel meliputi:

1. Distribusi label ABSA.
2. Distribusi panjang review.
3. Distribusi jumlah kata per review.
4. Distribusi jumlah label per review.
5. Correlation matrix antar label.

4.4 Feature Engineering / Representasi Teks

Representasi teks yang digunakan adalah:

1. TF-IDF.
2. Bag of Words.

TF-IDF digunakan karena mampu memberikan bobot lebih besar pada kata yang penting dalam dokumen. Bag of Words digunakan sebagai pembanding karena merepresentasikan teks berdasarkan frekuensi kemunculan kata atau n-gram.

Dengan membandingkan TF-IDF dan Bag of Words, eksperimen dapat menunjukkan pengaruh representasi teks terhadap performa model multilabel.

4.5 Model Training dan Eksperimen

Model yang dibandingkan adalah:

No	Model
1	TF-IDF + OneVsRest Logistic Regression
2	Bag of Words + OneVsRest Logistic Regression
3	TF-IDF + Classifier Chain Logistic Regression
4	TF-IDF + OneVsRest Linear SVM
5	Tuned TF-IDF + OneVsRest Logistic Regression

Pendekatan problem transformation yang digunakan adalah OneVsRest dan Classifier Chain. Pada

model Logistic Regression dan Linear SVM digunakan `class_weight="balanced"` untuk membantu mengurangi efek label imbalance.

Pada eksperimen tuning, parameter TF-IDF dan Logistic Regression disesuaikan dengan menaikkan `max_features`, memperluas `gram_range`, dan mengatur parameter `C`.

4.6 Hasil Evaluasi Validation Set

Hasil evaluasi pada validation set adalah:

Model	Micro-F1	Macro-F1	Weighted-F1	Hamming Loss	Subset Accuracy
Tuned TF-IDF + OneVsRest Logistic Regression	0.7139	0.4483	0.7173	0.0886	0.3619
TF-IDF + OneVsRest Logistic Regression	0.7066	0.4514	0.7160	0.0916	0.3476
TF-IDF + OneVsRest Linear SVM	0.7162	0.4505	0.7140	0.0853	0.3619
Bag of Words + OneVsRest Logistic Regression	0.7122	0.4425	0.7031	0.0850	0.3857
TF-IDF + Classifier Chain Logistic Regression	0.6784	0.4047	0.6877	0.1007	0.3952

Berdasarkan hasil tersebut, model terbaik yang dipilih adalah:

Tuned TF-IDF + OneVsRest Logistic Regression

Model ini dipilih karena memiliki nilai `weighted-F1` tertinggi pada validation set, yaitu 0.7173. `Weighted-F1` digunakan sebagai pertimbangan utama karena dataset memiliki label imbalance.

4.7 Evaluasi Test Set Multilabel

Model terbaik diuji pada test set dan memperoleh hasil sebagai berikut:

Metrik	Nilai
Micro-F1	0.7021
Macro-F1	0.5036
Weighted-F1	0.7224
Hamming Loss	0.0941
Subset Accuracy	0.3318

Pada multilabel classification, subset accuracy lebih rendah karena prediksi dianggap benar hanya jika seluruh label dalam satu review sama persis dengan ground truth. Oleh karena itu, metrik seperti Micro-F1, Macro-F1, dan Weighted-F1 lebih representatif untuk menilai performa model.

Weighted-F1 sebesar 0.7224 menunjukkan bahwa model cukup baik dalam memprediksi label dominan. Namun, Macro-F1 yang lebih rendah menunjukkan bahwa performa model belum merata pada semua label, terutama label minoritas.

4.8 Analisis Kesalahan Multilabel

Berdasarkan hasil error analysis pada test set, terdapat:

Status Prediksi	Jumlah
Exact match benar	70
Tidak exact match	141

Beberapa pola kesalahan yang ditemukan adalah:

1. Model masih sering menambahkan label tambahan yang tidak ada pada ground truth.
2. Model cenderung memprediksi label dominan seperti `PRODUCT_POSITIVE`.
3. Model masih sulit memprediksi label minoritas seperti `PRICE_NEUTRAL`, `PLACE_NEUTRAL`, dan `PROMOTION_NEUTRAL`.
4. Model dapat menghasilkan label kontradiktif pada aspek yang sama.
5. Kalimat negasi seperti tidak enak dapat membingungkan model.

Untuk mengurangi kesalahan pada deployment, dilakukan threshold tuning dan post-processing sederhana berdasarkan error analysis. Post-processing ini tidak menggantikan model utama, tetapi hanya memperbaiki output yang jelas kontradiktif, misalnya:

- Baksonya tidak enak menjadi `PRODUCT_NEGATIVE`.
- Harga mahal menjadi `PRICE_NEGATIVE`.
- Harga murah menjadi `PRICE_POSITIVE`.

5. Proyek B: Named Entity Recognition ABSA

5.1 Alur Pemodelan NER

Pada proyek NER, input model adalah token dari teks review, sedangkan output model adalah tag BIO untuk setiap token. Tahapan yang dilakukan adalah:

1. Membaca dataset anotasi JSONL.
2. Memvalidasi token dan span.
3. Mengonversi span menjadi tag BIO.
4. Membagi data menjadi train, validation, dan test.
5. Membuat vocabulary token dan tag mapping.
6. Melakukan padding dan truncation.
7. Melatih model BiLSTM.
8. Mengevaluasi model pada test set.
9. Menyimpan model dan mapping untuk deployment.

5.2 Data Loading dan Validasi Span

Dataset NER menggunakan file yang sama, yaitu Kelp4_dataset_anotasi.jsonl. Data yang digunakan adalah data dengan status answer = accept dan memiliki label.

Validasi span dilakukan untuk memastikan bahwa setiap span memiliki token_start dan token_end yang valid, serta berada dalam rentang token review. Hasil validasi menunjukkan bahwa data NER final berjumlah 2103 data.

Keterangan	Jumlah
Data awal	2118
Data dengan answer = accept	2117
Data tanpa label	14
Data NER valid	2103

5.3 Tokenization dan Konversi BIO

Data span dari Prodigy dikonversi menjadi format BIO. Label span yang awalnya memuat aspek dan sentimen, misalnya PRODUCT_POSITIVE, dikonversi menjadi aspek utama PRODUCT.

Contoh konversi BIO:

Token	Tag
Semuanya	B-PRODUCT
worth	I-PRODUCT
bakso	I-PRODUCT
mozanya	I-PRODUCT
enak	I-PRODUCT
banget	I-PRODUCT

Dataset NER kemudian dibagi menjadi train, validation, dan test.

Split	Jumlah Data
Train	1682
Validation	210
Test	211

5.4 EDA dan Visualisasi Entitas

EDA pada NER dilakukan untuk memahami distribusi token dan entitas. Visualisasi yang digunakan meliputi:

1. Distribusi jumlah token per review.

2. Distribusi tag BIO.
3. Distribusi jumlah span per entitas.
4. Distribusi jumlah entitas per review.

Distribusi tag BIO menunjukkan bahwa tag I-PRODUCT dan O sangat dominan, sedangkan tag B-PRICE memiliki jumlah paling sedikit. Hal ini menunjukkan adanya imbalance pada data NER.

Tag	Jumlah
I-PRODUCT	19958
O	18816
I-PLACE	6937
I-PROMOTION	5050
B-PRODUCT	2849
I-PRICE	1411
B-PLACE	941
B-PROMOTION	603
B-PRICE	261

5.5 Feature Engineering, Embedding, dan Tag Mapping

Pada proyek NER, dilakukan beberapa tahap feature engineering:

1. Membuat vocabulary token dari data train.
2. Menambahkan token khusus PAD dan UNK.
3. Membuat mapping tag ke indeks.
4. Melakukan encoding token dan tag.
5. Melakukan padding dan truncation.

Jumlah vocabulary token yang digunakan adalah 4742. Tag BIO yang digunakan berjumlah 9 tag. Panjang maksimum sequence ditentukan sebesar $MAX_LEN = 80$.

Strategi untuk mengurangi efek imbalance adalah menggunakan validation set, early stopping, mengabaikan token PAD saat evaluasi, dan melakukan analisis kesalahan token-level.

5.6 Model Configuration, Training, dan Validation NER

Model NER yang digunakan adalah BiLSTM. Arsitektur model terdiri dari:

1. Embedding layer.
2. Bidirectional LSTM.
3. Dropout.
4. TimeDistributed Dense dengan aktivasi softmax.

Model dilatih menggunakan optimizer Adam, loss `sparse_categorical_crossentropy`, batch size 32, maksimal 10 epoch, dan early stopping berdasarkan validation loss.

Hasil training menunjukkan bahwa model berhenti pada epoch ke-8 karena early stopping. Nilai validation loss terbaik terjadi pada epoch ke-5, yaitu 1.0941.

5.7 Evaluasi Test Set NER

Evaluasi NER dilakukan pada test set dengan mengabaikan token PAD. Jumlah token yang dievaluasi adalah 4876 token.

Hasil evaluasi utama model NER adalah:

Metrik	Nilai
Accuracy	0.6651
Macro-F1	0.4240
Weighted-F1	0.6365

Model cukup baik dalam mengenali tag dominan seperti I-PRODUCT, I-PLACE, dan O. Namun, model masih lemah dalam mengenali tag minoritas seperti B-PRICE, B-PROMOTION, dan I-PROMOTION.

5.8 Analisis Kesalahan NER

Berdasarkan hasil prediksi token, terdapat:

Status Token	Jumlah
Benar	3243
Salah	1633

Jenis kesalahan NER dibagi menjadi tiga kategori:

Jenis Error	Jumlah
Entity vs O Error	1270
Boundary Error	220
Label Error	143

Kesalahan paling banyak adalah Entity vs O Error. Artinya, model masih sering salah membedakan token yang termasuk entitas dan token biasa. Selain itu, terdapat Boundary Error ketika model salah membedakan tag B- dan I-, serta Label Error ketika model salah menentukan jenis aspek.

6. Deployment Streamlit

Aplikasi deployment dibuat menggunakan Streamlit dengan file:

`Kelp4_app.py`

Aplikasi memiliki tiga tab utama:

1. Prediksi Multilabel ABSA.
2. Prediksi NER ABSA.

3. Hubungan Multilabel dan NER.

Model yang digunakan pada aplikasi adalah model hasil training, yaitu model multilabel dan model NER. Pada tab Multilabel ABSA, aplikasi menampilkan input review, label yang diprediksi, confidence score, threshold, dan interpretasi hasil. Pada tab NER ABSA, aplikasi menampilkan token, predicted tag, entitas/aspek yang diekstraksi, dan highlight span. Pada tab hubungan, aplikasi menjelaskan hubungan antara hasil multilabel dan hasil NER.

Post-processing pada aplikasi digunakan sebagai tahap tambahan berdasarkan error analysis. Post-processing ini tidak menggantikan model utama, tetapi membantu mengurangi hasil prediksi yang kontradiktif.

7. Hubungan antara Multilabel Classification dan NER

Multilabel Classification dan NER saling melengkapi. Multilabel Classification bekerja pada level review dan menjawab aspek apa yang dibahas serta bagaimana sentimennya. Contohnya, sebuah review dapat diprediksi sebagai `PRODUCT_POSITIVE` dan `PRICE_NEGATIVE`.

NER bekerja pada level token atau span dan menjawab bagian teks mana yang menunjukkan aspek tersebut. Contohnya, pada review:

Baksonya enak, tempatnya luas, tapi harganya mahal.

Multilabel dapat menghasilkan:

- `PRODUCT_POSITIVE`
- `PLACE_POSITIVE`
- `PRICE_NEGATIVE`

NER dapat menandai:

- Baksonya enak sebagai `PRODUCT`
- tempatnya luas sebagai `PLACE`
- harganya mahal sebagai `PRICE`

Dengan demikian, Multilabel Classification memberikan label aspek dan sentimen, sedangkan NER memberikan lokasi span/aspek dalam teks.

8. Keterbatasan Proyek

Beberapa keterbatasan proyek ini adalah:

1. Dataset memiliki distribusi label yang tidak seimbang.
2. Label minoritas seperti `PRICE_NEUTRAL`, `PLACE_NEUTRAL`, dan `PROMOTION_NEUTRAL` sulit diprediksi.
3. Model multilabel masih dapat salah pada kalimat negasi atau label yang kontradiktif.
4. Model NER masih lemah pada aspek price dan promotion.
5. Banyak kesalahan NER berupa Entity vs O Error.
6. Tokenisasi NER pada Streamlit masih menggunakan tokenisasi sederhana.

7. Post-processing hanya memperbaiki beberapa pola kesalahan umum, bukan semua kemungkinan kesalahan.


9. Kesimpulan



Proyek ini berhasil membangun dua model NLP untuk ABSA review Google Places, yaitu Multilabel Text Classification dan Named Entity Recognition.

Pada proyek Multilabel Text Classification, model terbaik adalah Tuned TF-IDF + OneVsRest Logistic Regression. Model ini memperoleh Micro-F1 sebesar 0.7021, Macro-F1 sebesar 0.5036, Weighted-F1 sebesar 0.7224, Hamming Loss sebesar 0.0941, dan Subset Accuracy sebesar 0.3318 pada test set. Model cukup baik dalam memprediksi label dominan, tetapi masih memiliki keterbatasan pada label minoritas.

Pada proyek NER, model yang digunakan adalah BiLSTM dengan skema BIO. Model memperoleh accuracy sebesar 0.6651, Macro-F1 sebesar 0.4240, dan Weighted-F1 sebesar 0.6365. Model cukup baik dalam mengenali tag dominan, tetapi masih sulit mengenali tag minoritas seperti B-PRICE, B-PROMOTION, dan I-PROMOTION.

Aplikasi Streamlit berhasil dibuat untuk menampilkan prediksi Multilabel ABSA, prediksi NER ABSA, dan hubungan antara kedua output. Sistem ini dapat digunakan sebagai prototipe ABSA yang menampilkan aspek, sentimen, serta span/aspek dari review pelanggan.





10. Pembagian Tugas Anggota

Nama	NIM	Tugas
Natanael Denis Putra Christmas	230712245	Modeling multilabel classification, evaluasi multilabel, Data loading, validasi dataset,
Beny Ronald Aditama	230712427	preprocessing, konversi span ke BIO, modeling NER, dan evaluasi NER, Streamlit deployment, dokumentasi, laporan, screenshot, dan video demo